Прогнозирование объёмов отгрузок со складов

Хакатон RWB

Кречетов Роман

2025

github.com/rkk-droid/rwb-hack-2026

Постановка задачи

Что предсказываем

`target_1h` — объём отгрузок по маршруту за час

8 шагов вперёд ($\times 30$ мин = **4 часа**)

1 000 маршрутов $\times$ 8 шагов = 8 000 предсказаний

Признаки

`status_1..3` — этапы обработки на *текущем* складе

`status_4..6` — этапы обработки на *предыдущем* складе

Метрика

$$\text{WAPE} + \text{RelBias} = \frac{\sum |y_i - \hat{y}_i|}{\sum y_i} + \left| \frac{\sum \hat{y}_i}{\sum y_i} - 1 \right|$$

Особенность данных

Признаки `status_4/5` в августе и сентябре аномальны: *«бугор»* в сентябре, просадки в августе. Таргет при этом ведёт себя значительно нормальнее.

Решение: обучение **только на октябре.**

Архитектура решения

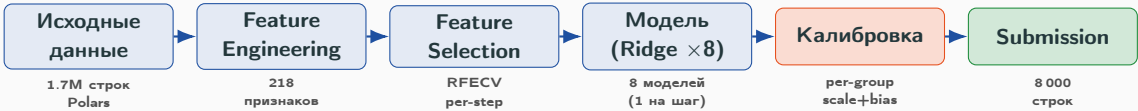

Ключевая идея: 8 независимых моделей — каждая обучается предсказывать конкретный шаг горизонта.

Признаки генерируются через **Polars LazyFrame** — 5–10× быстрее Pandas на 1.7M строк.

Feature Engineering — 218 признаков

1. Статусные признаки
Суммы и пропорции статусов 1–3 и 4–6.
Чем больше товаров на поздних этапах — тем ближе отгрузка.

2. Лаговые признаки (14 лагов)
Краткосрочные: 1, 2, 3, 4, 6, 8 шагов
Долгосрочные: 24, 48 . . . 336 шагов (до 7 дней)
Для всех 6 статусов + `target_1h`

3. Скользящие статистики
mean + std по окнам 5, 10, 48, 336.
Краткосрочная и долгосрочная волатильность.

4. Недельная периодичность
`mean_sum_1h_lag_327..336` — среднее по значениям через 1, 2, . . . недели *в обе стороны.*
Сглаживает шум отдельных лагов.

5. Временные признаки
One-hot: час суток (24), день недели (7), is_weekend.

6. Target encoding
`route_mean`, `route_hour_mean`, `route_weekday_mean`.
Средний профиль маршрута.

Feature Selection — RFECV per step

Проблема: важность признаков меняется в зависимости от горизонта.

Решение: отдельная маска признаков для каждого из 8 шагов.

Метод: RFECV + Ridge + 3-fold CV на 300 000 строк.

Шаг	Отобрано	Всего
1	204	216
2	212	
3	155	
4	131	
5	127	
6	121	
7	146	
8	168	

Наблюдение

На шагах 5–6 отбирается меньше всего признаков — **«переходная зона»**:

> краткосрочные лаги уже не предсказывают
>
> недельный паттерн ещё не работает в полную силу

К шагам 7–8 недельные лаги (336 периодов) снова подключаются.

Модель: Multi-step Ridge Regression

Почему Ridge, а не Gradient Boosting?

- Бустинг проверен — работает заметно хуже, вероятно из-за трудностей с обобщением на 1 000 маршрутов с разными масштабами и паттернами
- Ridge + StandardScaler корректно обрабатывает **коллинеарные** лаговые признаки
- L_2-регуляризация предотвращает переобучение при 200+ признаках

Пайплайн: `StandardScaler` $\rightarrow$ `Ridge(`α`=4.0)`

Train MAE по шагам:

Шаг	Train MAE
1	71 534
2	90 047
3	93 119
4	95 093
5	96 131
6	96 619
7	96 819
8	96 828

Ошибка растёт с горизонтом и *стабилизируется* к шагу 5–8.

Калибровка прогнозов

Идея: метрика WAPE + RelBias допускает прямую оптимизацию смещений.

Метод	Итого	WAPE	RelBias
Без калибровки	0.3354	0.3281	0.0073
1. Глобальный скаляр	0.3275	0.3275	0.0000
2. Per-group bias	0.3260	0.3260	0.0000
3. Per-group scale+bias	**0.3255**	**0.3255**	**0.0000**

$0.3354 \longrightarrow 0.3255$ (-3%)

Метод 3 — для каждой пары (маршрут × шаг):

$$\hat{y}' = k_{r,s} \cdot \hat{y} + b_{r,s}$$

16 000 параметров

Оптимизатор: **L-BFGS-B** с аналитическими градиентами

Функция потерь = *метрика соревнования*

$k \in [0, 3], \quad b \in \mathbb{R}$

Нормализация для устойчивости градиента

Итоги

Результаты

Val метрика (WAPE + RelBias): **0.325**

Позиция в лидерборде: **24 / 228**

Предсказания: 8 000 строк

Ключевые решения

- ✓ Multi-step: отдельная модель на горизонт
- ✓ RFECV per-step: разные признаки для разных горизонтов
- ✓ Недельная периодичность через кратные лаги
- ✓ Калибровка напрямую на метрике соревнования
- ✓ Per-group параметры (маршрут × шаг)
- ✓ Обучение только на октябре

Обобщаемость — ключевое преимущество

Все тестовые данные — **субботы с 10:30 до 14:00**.

Модель обучалась на *всех* днях недели и временных отметках без подгонки под конкретный срез теста.

Позиция **24/228** достигнута без переобучения под тест — решение *устойчиво к сдвигу распределения*.